

Bots and how to catch them

Detekcija AI-generiranih Reddit komentara


STEM Games 2026 – Mathematics arena x Erste

2026

- Društvene mreže – danas više od 5,4 milijarde korisnika
- Značaj dio prometa čine botovi (good i bad)
- Problem bad botova – ozbiljna društvena prijetnja
- Spam, phishing, manipulacija raspravama i umjetno povećanje angažmana
- Dead internet theory

Ukupan udio botova na webu


Ukupan udio botova (Bad + Good Bots)



Izvor: Statista, Human and bot web traffic share

Uspon “bad bot” prometa

Kvadratna aproksimacija rasta “Bad Bot” prometa




Izvor: Statista, Human and bot web traffic share

Ključne metrike bot prometa

Kategorija	Metrika	Vrijednost
Promet	Udio botova u ukupnom prometu	53%
	Udio ljudskog prometa	47%
Sigurnost	Udio “loših” botova	40%
	Godišnji porast AI bot napada	12.5x
Infrastruktura	Bot napadi na API-je	27%
	Bot napadi na poslovnu logiku	21%
Metode	Botovi koji koriste Chrome za prikrivanje	41%
Industrija	Napadi na financijske usluge	24%
	Preuzimanje računa u financijama	46%

Izvor: Thales/Imperva, Bad Bot Report 2026

- Detekcija i procjena vjerojatnosti AI generiranih komentara i objava
- Stvaramo sustav koji spaja tri komplementarna pogleda u ansambl modela (ensemble learning)
- Semantički pogled na značenje komentara, strukturni pogled na gradu rečenica i interpunkciju te leksički pogled na riječi, tokene i kratke znakovne obrasce
- Završni stacking meta-model (kombinira 3 podsustava)



Tri komplementarna pogleda: značenje, struktura i lokalni tekstualni obrasci.

$$y = 1 \Leftrightarrow \text{AI}, \quad y = 0 \Leftrightarrow \text{HUMAN}$$

$$p(t) \approx P(y = 1 \mid t)$$

$$\hat{y} = \mathbf{1}\{p(t) \geq 0.5\}$$

Podsustav	Signal
SVM	semantički embedding
Stabla	20 strukturnih značajki
TF-IDF	1.56M rijetkih n -grama
Meta-model	kombinacija vjerojatnosti

Model 1: Semantički SVM

Prikaz komentara

$$\hat{x} = \frac{x}{\|x\|_2}, \quad z_j = \frac{\hat{x}_j - \mu_j}{\sigma_j}$$

Linearna odluka

$$f(z) = w^\top z + b$$

$$p_{\text{sem}}(t) \approx P(y = 1 \mid t)$$

- Embedding model mapira tekst u prostor značenja.
- LinearSVC razdvaja standardizirane embeddinge.
- Vjerojatnost se dobiva Plattovom kalibracijom.

$$P(y = 1 \mid s) \approx \frac{1}{1 + \exp(As + B)}$$

Semantički SVM: margina i rezultati

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^n \max\{0, 1 - \tilde{y}_i (w^\top z_i + b)\}$$

$$\text{širina margine} = \frac{2}{\|w\|_2}$$

Metrika	Dev
Točnost	0.90948
Preciznost	0.90341
Odziv	0.91283
F_1	0.90810
ROC AUC	0.96885

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	19549	2022
$y = 1$	1806	18912

Model 2: Stablasti model

Ulaz

$$x \in \mathbb{R}^{20}$$

Značajke: broj riječi i rečenica po odlomku, upitnici, apostrofi, zagrade, crtice, duljine rečenica, prijelazne riječi i brojčane reference.


Ansambl stabala

$$F_M(x) = \beta_0 + \eta \sum_{m=1}^M T_m(x)$$

$$p_{\text{tree}}(x) = \frac{1}{1 + e^{-F_M(x)}}$$

HistGradientBoostingClassifier: dubina 5, stopa učenja 0.06, 300 iteracija.

Stablasti model: najvažnije značajke



Najveći doprinos: broj riječi po odlomku, broj rečenica po odlomku, apostrofi, upitnici i varijabilnost duljine rečenica.

Stablasti model: rezultati

Metrika	Dev
Točnost	0.90487
Uravnotežena točnost	0.9051
Preciznost	0.89214
Odziv	0.91664
F_1	0.90423
ROC AUC	0.96696

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	19275	2296
$y = 1$	1727	18991

Model 3: TF-IDF logistička regresija

TF-IDF

$$\text{tf}(t, g) = 1 + \log c_{t,g}$$

$$\text{idf}(g) = \log \frac{1 + N}{1 + \text{df}(g)} + 1$$

$$\tilde{x}_g(t) = \text{tf}(t, g) \text{idf}(g)$$

Dvije vrste n -grama

Riječi	1–2 grama
Znakovi	3–5 grama

$$x(t) = \begin{bmatrix} x_{\text{word}}(t) \\ x_{\text{char}}(t) \end{bmatrix} \in \mathbb{R}^{1557681}$$

TF-IDF logistička regresija: odluka i gubitak

$$s_c(x) = w_c^\top x + b_c$$

$$p_{\text{tf}}(t) = \frac{\exp(s_{\text{AI}}(x(t)))}{\exp(s_{\text{AI}}(x(t))) + \exp(s_{\text{HUMAN}}(x(t)))}$$

$$\min_w \sum_{i=1}^n \alpha_{y_i} [-y_i \log p_i - (1 - y_i) \log(1 - p_i)] + \lambda \|w\|$$

Koristi se `class_weight=balanced`; rjeđi razred dobiva veću težinu u gubitku.

TF-IDF logistička regresija: rezultati

Metrika	Dev
Točnost	0.98085
Preciznost	0.98627
Odziv	0.97447
F_1	0.98033
ROC AUC	0.99780
Log-gubitak	0.06739
Brier	0.01626

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	21290	281
$y = 1$	529	20189

Najjači pojedinačni bazni model.

Stacking: kako spajamo tri modela

$$p_{\text{sem}}(t), \quad p_{\text{tree}}(t), \quad p_{\text{tf}}(t)$$

$$p_{\text{meta}}(t) \approx P(y = 1 \mid p_{\text{sem}}, p_{\text{tree}}, p_{\text{tf}})$$

- Train ulazi za meta-model dobiveni su out-of-fold postupkom.
- Finalni bazni modeli treniraju se na cijelom train skupu.
- Meta-model je logistička regresija nad logitima i interakcijama.

$$\ell_i = \log \frac{p_i}{1 - p_i}, \quad p_i \in [10^{-5}, 1 - 10^{-5}]$$

$$\ell_1 = \text{logit}(p_{\text{sem}}), \quad \ell_2 = \text{logit}(p_{\text{tree}}), \quad \ell_3 = \text{logit}(p_{\text{tf}})$$

$$\phi(t) = [\ell_1, \ell_2, \ell_3, \ell_1 \ell_2, \ell_1 \ell_3, \ell_2 \ell_3, \ell_1^2, \ell_2^2, \ell_3^2]$$

$$p_{\text{meta}}(t) = \sigma \left(\beta_0 + \sum_{i=1}^3 \beta_i \ell_i + \sum_{i < j} \beta_{ij} \ell_i \ell_j + \sum_{i=1}^3 \gamma_i \ell_i^2 \right)$$
$$\sigma(u) = \frac{1}{1 + e^{-u}}, \quad \hat{y} = \mathbf{1}\{p_{\text{meta}}(t) \geq 0.5\}$$

Interakcije dopuštaju modelu da razlikuje slaganje i proturječje baznih podsustava.

Usporedba modela na razvojnom skupu

Model	Točnost	Prec.	Odziv	F_1	AUC	Log-gub.	Brier
Semantički SVM	0.90948	0.90341	0.91283	0.90810	0.96885	0.22646	0.06715
Stablasti model	0.90487	0.89214	0.91664	0.90423	0.96696	0.23115	0.07009
TF-IDF logreg	0.98085	0.98627	0.97447	0.98033	0.99780	0.06739	0.01626
Meta-model	0.98406	0.98788	0.97949	0.98366	0.99840	0.04564	0.01240

Meta-model je najbolji po svim navedenim metrikama.

Konfuzijske matrice na razvojnom skupu

Model	TN	FP	FN	TP
Semantički SVM	19549	2022	1806	18912
Stablasti model	19275	2296	1727	18991
TF-IDF logreg	21290	281	529	20189
Meta-model	21322	249	425	20293

Meta-model

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	21322	249
$y = 1$	425	20293

Meta-model smanjuje i lažno pozitivne i lažno negativne primjere u odnosu na najjači pojedinačni model.

Test rezultat završnog modela

Točnost	Prec.	Odziv	F_1	AUC	Log-gub.	Brier
0.98406	0.98722	0.98016	0.98368	0.99842	0.04499	0.01226

$$p_{\text{meta}}(t) \in [0, 1]$$

Završni izlaz nije samo oznaka, nego procjena vjerojatnosti AI autorstva.

- Koristimo točno tri bazna modela: semantički SVM, stablasti model i TF-IDF logističku regresiju.
- Modeli gledaju različite signale: značenje, strukturu i lokalne tekstualne obrasce.
- Stacking meta-model kombinira njihove vjerojatnosti preko logita, interakcija i kvadratnih članova.
- Završni model postiže najbolji rezultat: dev accuracy 0.98406, test accuracy 0.98406.
- Sustav procjenjuje vjerojatnost AI-generiranosti komentara, a ne dokazuje identitet autora.