

Bots and how to catch them

Detekcija AI-generiranih Reddit komentara

STEM Games 2026 – Mathematics arena x Erste

2026

Problem koji rješavamo


- Fokusiramo se na komentare na Redditu: ulaz je samo tekst komentara.
- Cilj je binarna klasifikacija: **HUMAN** ili **AI**.
- Ne koristimo metapodatke: nema korisničke povijesti, karme, vremena objave ni IP adrese.
- To čini zadatak realističnim za lokalni alat, ali teži jer model mora prepoznati samo jezične tragove.

Zašto je rast botova važan?

- Procjenjuje se da velik dio sadržaja na društvenim mrežama više ne pišu ljudi.
- Botovi se koriste za spam, phishing, manipulaciju raspravama i umjetno povećanje angažmana.
- Chatbotovi mogu proizvoditi uvjerljive komentare u velikoj količini i malom vremenu.
- Ako se automatizirani sadržaj ne označi, korisnici teže procjenjuju kome i čemu mogu vjerovati.


Uspon “bad bot” prometa

Kvadratna aproksimacija rasta “Bad Bot” prometa



Ukupan udio botova na webu

Ukupan udio botova (Bad + Good Bots)



Izvor: Statista, Human and bot web traffic share

- Anomalija iz 2014. povezana je s masovnim sigurnosnim skeniranjima kao što su Heartbleed i Shellshock.
- Nakon toga dolazi pad zbog boljih sustava zaštite i optimizacije rada tražilica.
- Novi rast potiču automatizirani alati, scraping, API napadi i generativni AI.
- Zato se naš problem svodi na lokalno pitanje: može li se pojedini komentar označiti kao ljudski ili AI-generiran?

Ključne metrike bot prometa

Kategorija	Metrika	Vrijednost
Promet	Udio botova u ukupnom prometu	53%
	Udio ljudskog prometa	47%
Sigurnost	Udio “loših” botova	40%
	Godišnji porast AI bot napada	12.5x
Infrastruktura	Bot napadi na API-je	27%
	Bot napadi na poslovnu logiku	21%
Metode	Botovi koji koriste Chrome za prikrivanje	41%
Industrija	Napadi na financijske usluge	24%
	Preuzimanje računa u financijama	46%

Izvor: Thales/Imperva, Bad Bot Report 2026

Naš detekcijski sustav

- Sustav kombinira više tekstualnih signala jer jedan indikator nije dovoljno pouzdan.
- Perplexity komponenta mjeri koliko je komentar predvidljiv malom jezičnom modelu.
- Sentiment komponenta mjeri emocionalni ton i konzistentnost izražavanja.
- TF-IDF + logistička regresija u `tf-logreg/train.py` uči direktno iz riječi, fraza i znakova.
- Dodatno ćemo trenirati SVM i druge klasifikatore nad istim ili proširenim značajkama.
- Završna neuronska mreža spaja izlaze svih komponenti u jednu odluku HUMAN/AI.

Formalizacija zadatka

- Svaki komentar pretvaramo u par (x_i, y_i) , gdje je x_i tekst, a $y_i \in \{0, 1\}$.
- Koristimo oznaku $y_i = 1$ za AI komentar i $y_i = 0$ za ljudski komentar.
- Model uči funkciju:

$$f : \mathcal{X} \rightarrow [0, 1], \quad f(x_i) \approx P(y_i = 1 \mid x_i)$$

- Konačna odluka dobiva se pragom, najčešće 0.5:

$$\hat{y}_i = \begin{cases} 1, & f(x_i) \geq 0.5 \\ 0, & f(x_i) < 0.5 \end{cases}$$

Što radi `tf-logreg/train.py`?

- 1 Učitava CSV s obaveznim stupcima `comment` i `label`.
- 2 Briše retke bez komentara ili oznake.
- 3 Dijeli podatke na trening i test skup uz `stratify=y`, da omjer klasa ostane sličan.
- 4 Gradi `sklearn` pipeline: ekstrakcija značajki, zatim logistička regresija.
- 5 Ispisuje `accuracy`, `classification report` i `confusion matrix`.
- 6 Sprema naučeni model u `tf-logreg/reddit_ai_detector.joblib`.

Word TF-IDF

- Koristi riječi i parove riječi: `ngram_range=(1,2)`.
- Hvata fraze, tipične formulacije i tematske obrasce.
- `min_df=2` izbacuje izraze koji se pojave samo jednom.

Character TF-IDF

- Koristi nizove znakova duljine 3 do 5.
- Hvata interpunkciju, prefikse, sufikse i stil pisanja.
- Korisno je za kratke komentare i neobične obrasce teksta.

Obje skupine značajki spajaju se pomoću `FeatureUnion`.

Matematika TF-IDF reprezentacije

Term frequency

$$\text{tf}(t, d) = \frac{\text{broj pojavljivanja termina } t \text{ u dokumentu } d}{\text{ukupan broj termina u } d}$$

Inverse document frequency

$$\text{idf}(t) = \log \frac{N}{1 + \text{df}(t)}$$

TF-IDF težina

$$x_{t,d} = \text{tf}(t, d) \cdot \text{idf}(t)$$

Rijetki, ali informativni izrazi dobivaju veću težinu; česti i neinformativni izrazi dobivaju manju težinu.

Kakav je to model?

- Model je **linearna logistička regresija** nad visoko-dimenzionalnim TF-IDF vektorima.
- Ne razumije značenje teksta kao veliki jezični model, nego uči statističke obrasce koji razlikuju klase.
- Za svaku značajku nauči težinu: pozitivna težina gura odluku prema jednoj klasi, negativna prema drugoj.
- Koristi `class_weight="balanced"`, pa ne favorizira veću klasu ako su podaci neuravnoteženi.
- Prednost: brz, objašnjiv, radi lokalno na laptopu i može se lako ugraditi u API ili ekstenziju.

Matematička ideja logističke regresije

Linearna odluka

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

Pretvaranje u vjerojatnost

$$P(\text{AI} \mid x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

- Ulaz x je TF-IDF vektor komentara.
- Ako je vjerojatnost veća za AI, model vraća AI; inače vraća HUMAN.
- `predict_proba` daje numeričku sigurnost odluke.

Funkcija gubitka za logističku regresiju

- Model se trenira tako da minimizira pogrešku između stvarne oznake y_i i predikcije p_i .
- Za binarnu klasifikaciju koristi se log-loss, odnosno binarna unakrsna entropija.

$$p_i = P(y_i = 1 \mid x_i) = \sigma(w^T x_i + b)$$

$$\mathcal{L}(w, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

- Ako je model sigurno kriv, gubitak je velik.
- Ako je model sigurno točan, gubitak je blizu nule.

Zašto dodati SVM?

- SVM je jak baseline za tekst jer TF-IDF daje velike, rijetke i gotovo linearno odvojive vektore.
- Umjesto direktnog modeliranja vjerojatnosti, SVM traži granicu s najvećom marginom između klasa.
- Linearni SVM često dobro radi kada ima puno značajki i relativno malo šuma po značajci.

Optimizacijski cilj linearnog SVM-a

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(w^T x_i + b))$$

Ovdje je $y_i \in \{-1, 1\}$, a parametar C određuje kompromis između široke margine i grešaka na trening skupu.

Više algoritama, različite greške

- Logistička regresija daje dobro kalibrirane vjerojatnosti i objašnjive težine značajki.
- SVM može bolje iskoristiti marginu između klasa u TF-IDF prostoru.
- Stabla i boosting modeli mogu koristiti ručno izrađene stilometrijske značajke: duljina rečenica, interpunkcija, ponavljanja, omjer velikih slova.
- Perplexity model hvata predvidljivost teksta, što TF-IDF ne mjeri direktno.
- Sentiment model hvata emocionalni ton, intenzitet i stabilnost izražavanja.

jači sustav = različiti signali + različite pogreške + model za spajanje

Spajanje modela neuronskom mrežom

- Svaki osnovni model vraća score ili vektor značajki.
- Te izlaze spajamo u jedan meta-vektor:

$$h = [p_{\text{logreg}}, s_{\text{svm}}, p_{\text{perplexity}}, s_{\text{sentiment}}, z_{\text{style}}]$$

- Neuronska mreža zatim uči nelinearnu funkciju spajanja:

$$a^{(1)} = \text{ReLU}(W_1 h + b_1), \quad \hat{p} = \sigma(W_2 a^{(1)} + b_2)$$

- Time mreža može naučiti da neki modeli imaju veću težinu u određenim situacijama.

TODO

Ovdje dodati detalje trećeg dijela neuronske mreže.

Prediktivna moć na test skupu

Klasa	Precision	Recall	F1
AI	0.99	0.97	0.98
HUMAN	0.98	0.99	0.98
Ukupno	Accuracy = 0.9805		

	Pred. AI	Pred. HUMAN
Stvarno AI	20196	523
Stvarno HUMAN	303	21270

Evaluacija: `uv run python tf-logreg/test_data.py --data data/test.csv`

- `predict.py` i lokalni API koriste `model.predict_proba`.
- Izlaz nije samo oznaka, nego i raspodjela vjerojatnosti po klasama.
- Primjer izlaza API-ja: `label, score, probabilities, reason`.
- `score` je vjerojatnost klase koju je model odabrao.
- Visok `score` znači da je komentar sličan obrascima iz trening podataka; ne znači matematičku sigurnost da je autor zaista bot.

- Model ovisi o kvaliteti i reprezentativnosti označenog skupa podataka.
- Ako se stil AI komentara promijeni, stare TF-IDF značajke mogu izgubiti snagu.
- Ljudski komentari napisani formalno mogu izgledati kao AI, a AI komentari s namjernim greškama mogu izgledati ljudski.
- Vjerojatnosti logističke regresije treba tretirati kao korisnu mjeru pouzdanosti, ali ne kao konačan dokaz.
- Zato je najbolje kombinirati ovaj model s perplexity, sentiment i stilometrijskim značajkama.

- Trenutni model već radi lokalno i može se koristiti kroz FastAPI endpoint `/classify`.
- Chrome ekstenzija može slati Reddit komentare lokalnom API-ju i prikazivati oznaku korisniku.
- Sljedeći korak je meta-model koji prima: TF-IDF score, perplexity score, sentiment značajke i stilometrijske mjere.
- Za meta-model su praktični Random Forest, LightGBM ili XGBoost jer dobro rade sa strukturiranim značajkama.
- Sustav treba redovito ponovno trenirati jer se botovi i generativni modeli brzo mijenjaju.

- Bot promet raste i već čini velik dio interneta.
- Naš odabrani problem je detekcija AI-generiranih Reddit komentara samo iz teksta.
- TF-IDF + logistička regresija daje brz, lokalno izvediv i mjerljiv baseline.
- Na test skupu postiže oko 98% accuracy, ali rezultat treba interpretirati uz ograničenja skupa podataka.
- Najjače rješenje je kombinacija više tekstualnih komponenti, a ne oslanjanje na jedan signal.