

0.1 TF-IDF logistička regresija kao podsustav klasifikacije

Motivacija. Ovaj podsustav promatra komentar kao tekstualni niz i traži lokalne leksičke i znakovne obrasce. Za razliku od semantičkog SVM-a, ovdje se ne koristi gusto semantičko ugrađivanje rečenice; za razliku od stablastog modela, ne koriste se ručno zadane strukturne značajke. Model izravno uči iz riječi, parova riječi i kratkih nizova znakova. Takav pristup je osobito koristan jer AI-generirani komentari često ponavljaju karakteristične fraze, prijelaze, ritam izražavanja, interpunkcijske obrasce i dijelove formulacija koji se mogu uhvatiti bez dubljeg razumijevanja značenja.

Za komentar t ovaj podsustav daje vjerojatnost

$$p_{\text{tf}}(t) \approx P(y = 1 \mid t),$$

gdje $y = 1$ označava razred AI. Ta se vrijednost dalje koristi kao treći bazni ulaz završnog stacking modela.

TF-IDF prikaz teksta. Tekst se najprije pretvara u rijedak vektor značajki pomoću dva TF-IDF prikaza. Prvi prikaz koristi riječi i parove uzastopnih riječi, odnosno unigram i bigram značajke. Drugi prikaz koristi znakovne n -grame duljina od 3 do 5. U provedbi su to dvije komponente `FeatureUnion`-a: `word_tfidf` i `char_tfidf`. U oba se prikaza odbacuju značajke koje se pojavljuju u manje od 2 komentara ili u više od 95% komentara.

Za značajku g i komentar t neka je $c_{t,g}$ broj pojavljivanja značajke g u komentaru. Budući da je u modelu uključeno sublinearno skaliranje frekvencije, lokalni dio težine glasi

$$\text{tf}(t, g) = \begin{cases} 1 + \log c_{t,g}, & c_{t,g} > 0, \\ 0, & c_{t,g} = 0. \end{cases}$$

Ako je N broj komentara u skupu za učenje, a $\text{df}(g)$ broj komentara u kojima se značajka g pojavljuje, inverzna dokumentna frekvencija u standardnoj zaglađenoj inačici može se zapisati kao

$$\text{idf}(g) = \log \frac{1 + N}{1 + \text{df}(g)} + 1.$$

Neobrađena TF-IDF težina zatim je

$$\tilde{x}_g(t) = \text{tf}(t, g) \text{idf}(g),$$

a dobiveni vektor se L2-normalizira. Time vrlo česte riječi dobivaju manju relativnu važnost, dok izrazi koji su dovoljno česti da budu pouzdani, ali nisu svugdje prisutni, dobivaju jači signal.

Riječni i znakovni n -grami. Riječni dio modela koristi n -grame duljina 1 i 2. On hvata izraze poput pojedinačnih ključnih riječi, čestih fraza i lokalnih kombinacija riječi. Znakovni dio koristi n -grame duljina od 3 do 5, pa može uhvatiti i obrasce unutar riječi, dijelove sufiksa, interpunkcijske prijelaze, kontrakcije i tipične fragmente koji ne moraju biti cijele riječi.

Konačni vektor dobiva se konkatencijom ta dva prikaza:

$$x(t) = \begin{bmatrix} x_{\text{word}}(t) \\ x_{\text{char}}(t) \end{bmatrix} \in \mathbb{R}^d.$$

U finalnom modelu spremljenom za stacking rječnik riječnih TF-IDF značajki ima 793698 elemenata, a rječnik znakovnih TF-IDF značajki 763983 elemenata. Ukupno je dakle

$$d = 1557681$$

rijetkih značajki. Iako je dimenzija vrlo velika, svaki pojedini komentar aktivira samo mali dio tih značajki, pa je računanje učinkovito.

Logistička regresija nad rijetkim tekstualnim vektorom. Nakon vektorizacije trenira se logistička regresija s L2-regularizacijom i uravnoteženim težinama razreda. U provedbi se koristi `solver=liblinear` i `max_iter=2000`. Za razred c model računa linearni rezultat

$$s_c(x) = w_c^\top x + b_c.$$

Vjerojatnost razreda dobiva se normalizacijom tih rezultata. Za AI razred to možemo zapisati kao

$$p_{\text{tf}}(t) = P(y = \text{AI} \mid x(t)) = \frac{\exp(s_{\text{AI}}(x(t)))}{\exp(s_{\text{AI}}(x(t))) + \exp(s_{\text{HUMAN}}(x(t)))}.$$

U binarnom slučaju taj je zapis ekvivalentan sigmoidnoj funkciji nad jednom linearnom kombinacijom značajki. Važno je da model ostaje linearan u TF-IDF prostoru: pojedini koeficijent govori koliko prisutnost odgovarajućeg n -grama pomiče odluku prema jednom ili drugom razredu.

Optimizacija se može opisati minimizacijom regulariziranog logističkog gubitka

$$\min_w \sum_{i=1}^n \alpha_{y_i} [-y_i \log p_i - (1 - y_i) \log(1 - p_i)] + \lambda \|w\|_2^2,$$

gdje su α_{y_i} težine razreda. U provedbi se koristi `class_weight=balanced`, pa rjeđi razred dobiva veću težinu u gubitku. Time se smanjuje opasnost da model jednostavno favorizira brojniji razred.

Zašto je ovakav model prikladan. TF-IDF logistička regresija vrlo je jednostavna, ali je posebno jaka za zadatke u kojima razredi imaju prepoznatljive tekstualne obrasce. Velika prednost je što model ne mora učiti duboki jezični prikaz od početka: on samo traži koji su n -grami statistički povezani s razredom. Zbog toga je brz, jeftin za treniranje i vrlo dobar kao bazni model.

Druga važna prednost je komplementarnost. Semantički SVM može uhvatiti značenje komentara, a stablasti model makro-strukturu, ali TF-IDF logistička regresija hvata sitne lokalne tragove koje ta dva modela mogu propustiti. Upravo zato je korisna kao treći ulaz završnog meta-modela.

Izlaz podsustava. Spremljeni `sklearn` pipeline sadrži i TF-IDF vektorizatore i logistički klasifikator. Zato se novi komentar može izravno predati modelu, a funkcija `predict_proba` vraća vjerojatnosti razreda. U finalnom spremljenom modelu poredak klasa je

AI, HUMAN,

pa se za izlaz podsustava uzima stupac koji pripada razredu AI. Kad bi se model koristio samostalno, binarna odluka mogla bi se zadati pravilom

$$\hat{y} = \mathbf{1}\{p_{\text{tf}}(t) \geq 0.5\}.$$

U završnom sustavu ponovno je važnija sama vjerojatnost $p_{\text{tf}}(t)$, jer je ona ulaz u stacking meta-model.

Rezultati na razvojnem skupu. Na razvojnem skupu finalni TF-IDF logistički model postiže točnost 0.98085, preciznost 0.98627, odziv 0.97447, mjeru $F_1 = 0.98033$ i pokazatelj ROC AUC = 0.99780. Budući da model vraća vjerojatnosti, korisne su i vjerojatnosne metrike: logaritamski gubitak iznosi 0.06739, a Brierova mjera 0.01626.

Konfuzijska matrica na razvojnem skupu iznosi

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	21290	281
$y = 1$	529	20189

Ovaj podsustav je najjači pojedinačni bazni model u trenutnoj izvedbi. Ipak, završni meta-model dodatno poboljšava rezultat jer iskorištava slučajeve u kojima se TF-IDF signal može potvrditi ili ispraviti semantičkim i strukturnim signalom.

Mogućnost jednostavnog poboljšanja. Najjednostavnije poboljšanje ovoga podsustava bilo bi sustavno podešavanje hiperparametara TF-IDF prikaza i logističke regresije: primjerice vrijednosti `min_df`, `max_df`, raspona riječnih i znakovnih n -grama te regularizacijskog parametra C . Drugi prirodan korak je dodatna kalibracija vjerojatnosti, jer je završnom stacking modelu važna kvaliteta samih vjerojatnosti, a ne samo točnost binarne odluke. Takve izmjene ne

bi promijenile osnovnu ideju modela, nego bi samo preciznije prilagodile istu linearnu metodu podacima.