

0.1 TF-IDF logistička regresija kao podsustav klasifikacije

Motivacija. Ovaj podsustav služi kao brz, lokalno izvediv i lako objašnjiv tekstualni model. Za razliku od semantičkog SVM-a, koji komentar najprije prevodi u gusti vektorski prikaz značenja, ovdje se izravno koristi površinski tekst: riječi, kratke fraze i nizovi znakova. Takav pristup polazi od pretpostavke da AI-generirani komentari često ostavljaju tragove u izboru izraza, ponavljanju fraza, interpunkciji, prefiksima, sufiksima i općem ritmu pisanja.

Model ne koristi metapodatke o korisniku, karmi, vremenu objave, povijesti računa ili subredditu. Ulaz je isključivo tekst komentara t , a izlaz je procjena vjerojatnosti

$$p_{\text{tf}}(t) \approx P(y = 1 \mid t),$$

gdje $y = 1$ označava razred **AI**, a $y = 0$ razred **HUMAN**. Time je podsustav namjerno ograničen, ali je zato jednostavan za pokretanje, brz za inferenciju i prikladan kao jedan od ulaza šireg ansambla.

Ulazni podaci i cjevovod. Skripta `train.py` očekuje CSV datoteku sa stupcima `comment` i `label`. Retci kojima nedostaje komentar ili oznaka uklanjaju se prije treniranja, a oznake se tretiraju kao tekstualne vrijednosti. Skup se zatim dijeli na dio za učenje i dio za testiranje pomoću stratificirane podjele. Stratifikacija čuva približno isti omjer razreda u oba podskupa, što je važno jer bi obična slučajna podjela mogla dati nereprezentativan testni skup.

U implementaciji je cijeli postupak spremljen kao jedan `scikit-learn Pipeline`. To znači da spremljena datoteka `reddit_ai_detector.joblib` ne sadrži samo završni klasifikator, nego i pretvorbu teksta u značajke. Novi komentar zato se može izravno proslijediti metodama `predict` i `predict_proba`, bez ručnog računanja vektora.

TF-IDF prikaz. Komentar se najprije pretvara u rijedak numerički vektor pomoću TF-IDF težina. Za termin u i dokument d osnovna težina ima oblik

$$x_{u,d} = \text{tf}(u, d) \cdot \text{idf}(u),$$

gdje $\text{tf}(u, d)$ opisuje koliko se termin često pojavljuje u komentaru, a $\text{idf}(u)$ smanjuje težinu termina koji se pojavljuju u velikom broju komentara. U pojednostavljenom obliku može se pisati

$$\text{idf}(u) = \log \frac{N}{1 + \text{df}(u)},$$

pri čemu je N ukupan broj dokumenata, a $\text{df}(u)$ broj dokumenata u kojima se termin pojavljuje. Intuicija je jednostavna: riječ ili obrazac koji se pojavljuje gotovo svugdje slabo razlikuje razrede, dok rjeđi obrazac može biti informativniji.

U stvarnoj provedbi koristi se `sublinear_tf=True`, pa se utjecaj vrlo čestih termina ublažava logaritamskom skalom. Ako je $c(u, d)$ broj pojavljivanja termina, tada se umjesto sirove frekvencije koristi oblik

$$\text{tf}_{\text{sub}}(u, d) = 1 + \log c(u, d)$$

za termine koji se u dokumentu pojavljuju. Time se sprječava da jedna višestruko ponovljena riječ previše dominira cijelim vektorom.

Riječne i znakovne značajke. Podsustav koristi dvije paralelne skupine TF-IDF značajki. Prva skupina su riječni n -grami s rasponom `ngram_range=(1, 2)`. Oni hvataju pojedinačne riječi i kratke fraze, primjerice stabilne izraze, česte prijelaze ili tipične formulacije.

Druga skupina su znakovni n -grami s rasponom `ngram_range=(3, 5)`. Oni ne ovise o potpunim riječima, nego hvataju kraće nizove znakova: nastavke riječi, prefikse, interpunkcijske obrasce, dijelove kontrakcija i formatiranje. To je korisno jer se stil pisanja često vidi upravo u sitnim lokalnim obrascima koji ne moraju biti cijele riječi.

Obje skupine koriste `min_df=2` i `max_df=0.95`. Prvi uvjet uklanja obrasce koji se pojavljuju samo jednom i vjerojatno su šum, a drugi uklanja obrasce koji su toliko česti da slabo razlikuju razrede. Dobiveni vektori spajaju se pomoću `FeatureUnion`, pa je konačni ulaz logističke regresije

$$x = \begin{bmatrix} x_{\text{word}} \\ x_{\text{char}} \end{bmatrix}.$$

Logistička regresija. Nad spojenim TF-IDF vektorom uči se linearna odlučna funkcija

$$s(x) = w^{\top} x + b.$$

Vrijednost $s(x)$ zatim se pretvara u vjerojatnost sigmoidnom funkcijom

$$P(y = 1 \mid x) = \sigma(s) = \frac{1}{1 + e^{-s}}.$$

Ako je ta vjerojatnost veća od vjerojatnosti suprotnog razreda, model vraća oznaku `AI`; inače vraća `HUMAN`. Važno je da je granica odluke linearna u prostoru TF-IDF značajki. To ne znači da je model primitivan: prostor značajki sadrži velik broj riječi, fraza i znakovnih obrazaca, pa linearna granica zapravo može kombinirati mnogo lokalnih tekstualnih signala.

Optimizacijska zadaća. Za skup primjera (x_i, y_i) logistička regresija minimizira binarnu unakrsnu entropiju. Ako je

$$p_i = \sigma(w^{\top} x_i + b),$$

tada je osnovni gubitak

$$\mathcal{L}(w, b) = - \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

U `scikit-learn` izvedbi zadana je i L_2 regularizacija, pa se uči kompromis između prilagodbe podacima i veličine težina:

$$\min_{w, b} \mathcal{L}(w, b) + \lambda \|w\|_2^2.$$

Regularizacija je posebno važna jer TF-IDF prikaz može imati vrlo velik broj dimenzija. Bez nje bi model lako previše povjerovao rijetkim izrazima koji su slučajno povezani s jednim razredom u skupu za učenje.

Uravnoteženje razreda. U kodu se koristi `class_weight="balanced"`. Time se pogreške na rjeđem razredu automatski jače kažnjavaju. Za razred c težina je razmjerna izrazu

$$\omega_c = \frac{n}{K n_c},$$

gdje je n ukupan broj primjera, K broj razreda, a n_c broj primjera razreda c . Time se smanjuje opasnost da model visoku točnost postigne samo favoriziranjem većinskog razreda.

Zašto je ovaj model prikladan kao osnovni tekstualni signal. Prednost TF-IDF logističke regresije jest u tome što je vrlo brza i stabilna. Treniranje i inferencija svode se na rad s rijetkim matricama i linearnim modelom, pa je postupak znatno jeftiniji od modela koji zahtijevaju duboke jezične reprezentacije. Uz to, težine modela imaju izravnu interpretaciju: pozitivna težina nekog obrasca gura odluku prema razredu `AI`, a negativna prema razredu `HUMAN`.

S druge strane, model ne razumije tekst u dubokom semantičkom smislu. Ako se ista namjera izrazi potpuno drukčijim riječima, TF-IDF model to može teže povezati nego model temeljen na semantičkim ugradnjama. Zato je ovaj podsustav najkorisniji kao komplementaran signal: dobro hvata leksičke i stilističke tragove, dok drugi podsustavi pokrivaju značenje i strukturu.

Izlaz podsustava. Za komentar t model vraća razredne vjerojatnosti dobivene metodom `predict_proba`. Samostalna binarna odluka može se zapisati kao

$$\hat{y} = \mathbf{1}\{p_{\text{tf}}(t) \geq 0.5\}.$$

U naredbenom retku `predict.py` ispisuje predviđenu oznaku i vjerojatnosti za oba razreda. U lokalnom API-ju iz datoteke `app.py` isti se spremljeni model koristi za endpoint `/classify`, koji vraća oznaku, pripadni rezultat i objašnjenje `TF-IDF + Logistic Regression model`.

Rezultati na testnom skupu. Spremljeni model `reddit_ai_detector.joblib` vrednovan je na skupu `data/test.csv`. Skup sadrži 42292 komentara, od čega 20719 s oznakom AI i 21573 s oznakom HUMAN. Dobivena je točnost

$$\text{accuracy} = 0.98047.$$

Za razred AI preciznost iznosi približno 0.99, odziv 0.97 i mjera $F_1 = 0.98$. Za razred HUMAN preciznost iznosi približno 0.98, odziv 0.99 i mjera $F_1 = 0.98$. Konfuzijska matrica, u redoslijedu redaka AI, HUMAN i stupaca $\hat{y} = \text{AI}$, $\hat{y} = \text{HUMAN}$, iznosi

	$\hat{y} = \text{AI}$	$\hat{y} = \text{HUMAN}$
$y = \text{AI}$	20196	523
$y = \text{HUMAN}$	303	21270

Rezultat pokazuje da ovaj jednostavan linearni model vrlo snažno razdvaja razrede na danom skupu. Ipak, vjerojatnosti treba tumačiti kao sličnost naučenim obrascima, a ne kao dokaz stvarnog autorstva.

Mogućnost jednostavnog poboljšanja. Najizravnije poboljšanje ovoga pod-sustava jest sustavno podešavanje hiperparametara TF-IDF prikaza i logističke regresije. Primjerice, moglo bi se ispitati šire raspone riječnih i znakovnih n -grama, drukčije vrijednosti `min_df` i `max_df`, jačinu regularizacije te kalibraciju vjerojatnosti na odvojenom razvojnom skupu. Takve promjene ne mijenjaju osnovnu arhitekturu, ali mogu poboljšati robusnost modela na nove stilove AI-generiranog teksta.