

0.1 Stablasti model kao podsustav klasifikacije

Motivacija. Ovaj podsustav polazi od drukčije pretpostavke od semantičkog SVM-a. Ovdje se ne traži primarno što komentar *znači*, nego *kako je građen*. U praksi se pokazuje da se mnogi AI-generirani komentari razlikuju po makro-strukturi, ritmu rečenica i interpunkcijskoj uporabi: češće su dulji, imaju više rečenica po odlomku, više upitnika, više apostrofa, veću varijabilnost duljine rečenica i češće koriste obrasce koji potiču nastavak interakcije. S druge strane, ljudski komentari češće zadržavaju neke obrasce koji su manje “angažmanski agresivni”, primjerice zgrade, točku-zarez, dvotočku ili brojčane reference. Zbog toga ima smisla zasebno modelirati strukturni sloj komentara i dopustiti stablastom modelu da upravo na takvim pravilima gradi odluku.

Ulazne značajke. Svaki se komentar prevodi u vektor

$$x \in \mathbb{R}^{20},$$

pri čemu komponente vektora opisuju rečenične i odlomkovne heuristike. Među njima su: broj rečenica po odlomku, broj riječi po odlomku, prisutnost desne zgrade, crtice, točke-zareza ili dvotočke, upitnika i apostrofa, standardna devijacija duljine rečenica, prosječna razlika duljina uzastopnih rečenica, prisutnost vrlo kratkih i vrlo dugih rečenica te binarni pokazatelji za izraze poput *although, however, but, because, this, others/researchers*, brojeve i *et*.

Empirijski nalazi iz skupa za učenje potvrđuju da takve značajke nose signal. Korelacija s AI oznakom najveća je za broj rečenica po odlomku (0.495), prisutnost upitnika (0.442), broj riječi po odlomku (0.414), prisutnost riječi *but* (0.362) i apostrofa (0.360). S druge strane, negativnu korelaciju s AI oznakom imaju prisutnost točke-zareza ili dvotočke (−0.179), desne zgrade (−0.163) i brojčanih referenci (−0.134). To znači da model ne polazi od proizvoljno zadanih pravila, nego od obrazaca koji su u podacima doista uočljivi.

Pojedinačno stablo kao osnovni mehanizam odluke. Ako se promatra jedno stablo odluke, tada se u svakom unutarnjem čvoru provjerava uvjet oblika

$$x_k \leq \tau,$$

gdje je x_k jedna od 20 značajki, a τ pripadni prag. Ako je uvjet zadovoljen, primjer se šalje u lijevu granu; inače u desnu. Taj se postupak ponavlja sve do lista.

Na razini jednog stabla list sadrži lokalnu procjenu razredne pripadnosti. Ako u listu ima n_H ljudskih i n_{AI} AI primjera, prirodna procjena AI-vjerojatnosti glasi

$$p_{\text{leaf}}(x) = \frac{n_{AI}}{n_H + n_{AI}}.$$

Upravo je zato pojedinačno stablo vrlo pogodno za objašnjavanje: odluka se može pratiti kao konačan niz pragova nad čitljivim značajkama.

Pojačano stablasto učenje. Stvarna klasifikacijska inačica ovoga podsustava ne koristi jedno stablo, nego pojačani ansambl stabala, konkretno `HistGradientBoostingClassifier`. Ideja je da se ne traži jedno veliko stablo koje mora samo riješiti cijeli problem, nego niz plitkih stabala koja se nadovezuju jedno na drugo i postupno ispravljaju prethodne pogreške.

Ako je s $T_m(x)$ označen doprinos m -tog stabla, tada se ukupni odlučni rezultat može zapisati u obliku

$$F_M(x) = \beta_0 + \eta \sum_{m=1}^M T_m(x),$$

gdje je β_0 početni član, η stopa učenja, a M broj stabala. Za binarnu klasifikaciju zatim se iz toga rezultata dobiva AI-vjerojatnost logističkom preslikbom

$$p_{\text{tree}}(x) = \frac{1}{1 + e^{-F_M(x)}}.$$

U ovoj provedbi koriste se parametri `max_depth=5`, `learning_rate=0.06`, `max_iter=300` i `min_samples_leaf=15`, uz rano zaustavljanje na izdvojenom dijelu skupa za učenje. Histogramska varijanta dodatno ubrzava učenje tako što kontinuirane značajke najprije grupira u binove, pa se pragovi više ne traže nad svim mogućim realnim vrijednostima, nego nad histogramiziranim prikazom podataka.

Zašto je stablasta metoda ovdje prikladna. Ovakav model ima dvije važne prednosti. Prvo, može prirodno modelirati nelinearne interakcije među značajkama. Nije isto je li komentar dug sam po sebi ili je istodobno dug, pun upitnika i s velikom varijabilnošću duljine rečenica; stablo i ansambl stabala takve kombinacije hvataju mnogo prirodnije od jedne linearne granice. Drugo, stablasti modeli ne zahtijevaju standardizaciju značajki na isti način kao linearni modeli, jer odluku temelje na usporedbi s pragovima, a ne na udaljenosti u linearnom prostoru.

Odnos između glavnog modela i objašnjive inačice. Za stvarnu klasifikaciju koristi se pojačani model, jer daje bolji rezultat na razvojnog skupu. Ipak, u repozitoriju postoji i način rada s jednim `DecisionTreeClassifier`-om. Ta inačica nije uvedena zato što je točnija, nego zato što omogućuje doslovan prolaz od korijena do lista za pojedini komentar. Time se dobiva egzaktna, vizualno čitljiv slijed pravila tipa “broj rečenica po odlomku > 2.595 ” ili “prisutan upitnik”, što je korisno kada se želi objasniti jednu konkretnu odluku.

Izlaz podsustava. Za komentar t podsustav vraća vjerojatnost

$$p_{\text{tree}}(t) \approx P(y = 1 \mid t),$$

gdje $y = 1$ ponovno označava razred AI. Kad bi se model koristio samostalno, binarna bi se odluka mogla zadati pravilom

$$\hat{y} = \mathbf{1}\{p_{\text{tree}}(t) \geq 0.5\}.$$

U završnom sustavu važniji je sam realni broj $p_{\text{tree}}(t)$ nego tvrda odluka, jer se ta vjerojatnost dalje kombinira s preostalim podsustavima.

Rezultati na razvojnem skupu. Pokretanjem zadanog pojačanog modela nad skupovima `train.csv` i `dev.csv` dobivene su vrijednosti točnosti 0.9049, uravnotežene točnosti 0.9051, preciznosti 0.8921, odziva 0.9166, mjere $F_1 = 0.9042$ i pokazatelja ROC AUC = 0.9670. Konfuzijska matrica na razvojnem skupu iznosi

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	19275	2296
$y = 1$	1727	18991

što pokazuje da model vrlo dobro razdvaja razrede i pritom zadržava vrlo snažnu sposobnost rangiranja.

Važnost značajki. Permutacijska važnost značajki potvrđuje da odluka modela nije raspodijeljena ravnomjerno po svim ulazima. Najveći doprinos imaju broj riječi po odlomku (0.1632) i broj rečenica po odlomku (0.0873), a zatim prisutnost apostrofa (0.0182), upitnika (0.0173), standardna devijacija duljine rečenica (0.0146) i razlika duljina uzastopnih rečenica (0.0089). Među važnijim signalima pojavljuju se još brojčane reference (0.0072), desna zagrada (0.0070), crtica (0.0044) i točka-zarez ili dvotočka (0.0036). To je u skladu s ranijom korelacijskom analizom: model najveću težinu daje upravo onim strukturnim obilježjima na kojima se AI i HUMAN komentari u podacima najjasnije razilaze.

Mogućnost jednostavnog poboljšanja. Najjednostavniji put do jače inačice ovoga podsustava nije zamjena samog klasifikatora, nego proširenje ulaznog skupa značajki. U istom direktoriju već postoje dodatne analize koje bilježe makro-strukturna pravila, prijelazne fraze, obrasce obraćanja, retoričke prijelaze i slične obrasce, ali ti signali još nisu svi uključeni u završni 20-dimenzionalni vektor na kojem se model trenira. Stoga je prirodan sljedeći korak ugraditi takve već izmjerene značajke u funkciju za ekstrakciju obilježja i zatim ponovno istrenirati isti pojačani model. To je tehnički jednostavno, a ima smisla upravo zato što su mnoge od tih razlika već empirijski potvrđene u pripadnim artefaktima.